

从“思维树”到金融智脑

——解读《Tree of Thoughts》及其对金融领域的启发

一、论文背景介绍

随着大语言模型（LLM）的迅速发展，人工智能在推理与复杂任务求解方面的能力边界不断被突破。然而，早期的语言模型在处理需要多步骤推理、战略规划或回溯纳错的任务时，往往表现不佳。这一局限性促使研究者探索更为系统化的推理框架。

2022 年，Chain of Thought（思维链，CoT）提示方法的提出是一个重要突破——通过让模型“一步一步地思考”，显著提升了其数学推理和逻辑推断能力。然而，CoT 本质上仍是线性的，模型只能沿单一路径推进，无法主动探索多个解题方向，也无法对中间过程进行自我评估与纳错。

在此背景下，来自普林斯顿大学与 Google DeepMind 的研究者 Shunyu Yao 等人于 2023 年提出了《Tree of Thoughts: Deliberate Problem Solving with Large Language Models》，并发表于 NeurIPS 2023，即神经信息处理系统年会，这是人工智能领域顶级会议之一。该论文的核心贡献在于：打破线性推理的局限，引入树形搜索结构，赋予语言模型“深思熟虑”的能力。

二、论文内容介绍

《Tree of Thoughts》（简称 ToT）提出了一种新型语言模型推理框架，其核心思想是将问题求解过程建模为在“思维树”上的搜索过程。

在传统 CoT 方法中，模型每次生成一个 token，整个推理路径是单一链条，缺乏对多种可能路径的比较与择优。ToT 的创新在于，它将每一个“中间思考步骤”视为树上的一个节点，即“思维”，允许从同一节点扩展出多个候选思路，再通过评估机制对各节点打分，最终通过广度优先搜索（BFS）或深度优先搜索（DFS）确定最优求解路径。

ToT 框架由三个核心组件构成：第一，思维生成（Thought Generation），即

在每一推理步骤，模型生成多个候选思路，而非单一输出；第二，思维评估（Thought Evaluation），模型对当前每条思路进行自我打分，判断其是否有助于最终解题；第三，搜索策略（Search Strategy），通过 BFS 或 DFS 在思维树上遍历，决定向哪条路径继续深入，或回溯至更优分支。

论文在三个基准任务上验证了 ToT 的有效性：Game of 24（数字游戏，需要通过四则运算凑出 24）、创意写作，以及 5×5 填字游戏。实验结果表明，ToT 在 Game of 24 中将成功率从 CoT 的 4% 大幅提升至 74%，充分证明了其在复杂多步推理场景中的优越性。

三、论文解读

从方法论角度解读，ToT 本质上是将经典搜索算法（如 BFS/DFS）与大语言模型的生成能力相结合。这种融合并非简单的技术叠加，而是从认知科学角度对“人类如何解决难题”进行了深刻建模。

人类思维分为直觉快速反应的“系统 1”和深思熟虑的“系统 2”。CoT 对应的是加速了的系统 1——它让模型“想得更多了”，但仍是线性地往前走；而 ToT 则真正引入了系统 2 的机制：主动生成多条假说，逐一评估，放弃劣势，聚焦优势。

此外，ToT 框架的另一关键贡献是引入了模型对自身输出的“元认知评估”——即让 LLM 不仅负责生成内容，还负责判断这些内容的价值。这种自我评估机制使得模型的推理过程更加透明和可控。

从局限性来看，ToT 显著增加了推理时的计算成本。由于需要多次调用语言模型来生成和评估不同思路，其 API 调用量是标准 CoT 的数倍甚至数十倍。如何在推理质量与计算效率之间取得平衡，是后续研究需要面对的核心挑战。

四、个人看法

在我看来，ToT 最具价值的地方并不仅仅是实验指标的提升，而是其背后对“AI 如何更像人类决策者”这一问题的深刻回答。在金融工程的学习过程中，我深切体会到：面对复杂的市场环境，好的决策从来不是一条路走到黑，而是在充分探索多种可能后，做出有根据的选择。

ToT 让我联想到我们在学习国际金融时讨论的 Dornbusch 汇率超调模型——汇率在短期内往往会过度反应，然后逐渐回归均衡。AI 推理也面临类似问题：单步生成往往是“过度自信”的，而 ToT 提供的多路径搜索机制，正是一种让模型在“超调”前先做多方评估的纳错机制。

当然，我也有保留意见：ToT 高度依赖于“思维评估”的质量。如果模型对思路的打分本身不准确，整个搜索过程可能会系统性地走向错误方向。在金融决策中，错误的评估标准往往比没有评估更危险。这提醒我们，在将 AI 推理框架引入金融场景时，评估准则的设计和验证是重中之重。

五、对金融领域的启发

ToT 的思想框架对金融领域具有多层次的启发价值，以下从三个维度展开分析。

（一）量化策略的多路径探索与评估

在量化投资中，策略选择本质上是一个在高维参数空间中搜索优质解的问题。借鉴 ToT，可以构建“策略思维树”：在每一个决策节点，如选股条件、仓位管理规则、止损策略生成多个候选方案，通过回测评分剪枝，逐步收敛至最优策略组合。ToT 的优势在于可以利用 LLM 的语义理解能力，对策略逻辑的合理性进行“定性评分”，而不仅仅依赖历史数据的量化回测。

（二）信用风控中的多维推理路径

信贷风控的核心挑战在于：单一的评分模型往往无法覆盖所有风险维度，而人工审核成本高。ToT 框架可以赋予 AI 信贷审核官的“多线程思维”：从还款能力、信用历史、行业风险、宏观环境不同角度分别生成风险判断，再通过综合评估机制加权得出最终结论。这种多路径推理比单一黑盒模型更具可解释性，满足金融监管对 AI 决策透明度的要求。

（三）财报分析与研报报告的结构化生成

在投资研究领域，分析一家公司的财务报告往往需要从多个角度切入：盈利能力、偿债能力、成长性、行业对比等。传统 LLM 处理此类任务时容易“遗漏视角”或产生“幻觉”。ToT 可以将每一个分析维度视为树上的一条分支，先分别深入分析，再在树的高层节点进行综合。这不仅提升了分析的系统性，也使得每一个结论

都有清晰的推理路径可供追溯与验证。

附录：与 AI 的对话记录

AI 名称：DEEPSEEK

我： ToT 和 CoT 的核心区别是什么？我感觉两个都是让模型“多想想”，本质有什么不同？

AI： CoT 是让模型把思考过程“说出来”，但路径是单一的、线性的，一旦走错了就很难回头。ToT 则是真正引入了“分叉”——在每一步都生成多个候选思路，然后评估哪条路更有价值，再决定往哪个方向深入。可以这样理解：CoT 是一个人闷头算草稿，ToT 是一个团队同时在黑板上写多种解法，然后大家评选最优方案再继续推进。

我： 这个“评估思路”是谁来做？还是模型自己吗？如果模型本身判断力有问题，那评估岂不是也不准确？

AI： ToT 的评估器本身也是 LLM，所以存在“裁判本身不可靠”的潜在问题。如果任务本身需要高度专业知识（比如金融风险的准确判断），纯靠通用 LLM 评估是不够的，可能需要引入外部规则或专家系统来辅助。这也是 ToT 的局限之一。

我： 那 ToT 能用在金融上吗？我在想量化策略是不是可以用这个思路，因为选因子本身就像在“搜索最优路径”？

AI： 这个类比非常到位。量化选股本质上就是在因子空间里搜索，ToT 的思路可以让 AI 自动“展开候选策略树”。不过要注意一个区别：金融里的“评分”是通过数据回测来客观衡量的，而 ToT 原始框架里的评分是 LLM 主观给出的。所以在金融应用中，你可以把“评估模块”替换成量化指标（夏普比率、最大回撤等），这样整个框架会更可靠。

我： 那它在风控上有没有应用潜力？我感觉信贷风控也很需要“多角度看问题”的能力。

AI： 你想到一个很有价值的应用场景。信贷决策确实需要从还款能力、信用历史、行业风险、宏观环境等多个维度综合判断，这天然契合 ToT 的多分支结构。更重要的是，ToT 的树形结构使每个结论都有清晰的推理路径，这对于满足金融监管对 AI 可解释性的要求非常关键。

我： 这篇论文最大的局限是什么？如果我要在论文里客观评价它，应该怎么说？

AI： 主要有两点局限值得指出：第一是计算成本，ToT 需要多次调用 LLM 来生成和评估多条思路，API 调用量是标准 CoT 的数倍，在实际部署中成本较高；第二是评估质量的天花板，ToT 的效果上限受限于“评估模块”的准确性，如果模型无法准确判断哪条思路更有价值，搜索过程可能反而走入误区。结合你在金融场景的思考——用量化指标替代 LLM 评估来规避第二个问题——会让你的论文评价显得很有深度。